

Minería de Datos y Big Data

Maestro: José Isidro Limones Martínez

Carrera: ISC (Ingeniería en Sistemas Computacionales)

UNIVERSIDAD AUTÓNOMA DE LA LAGUNA

UAL - Esfuerzo que Trasciende

**ANÁLISIS DE UN PROTOTIPO DE RECOMENDACIÓN DE VIDEO CORTO
MEDIANTE CRISP-DM, ORANGE DATA MINING Y PRUEBAS DE
LABORATORIO**

Reporte de estadía

para cumplir con los requisitos parciales para concluir la carrera de:

Ingeniería en Sistemas Computacionales e Informática

Presentado por:

Diego Hurtado Cisneros — 19512

Arturo Ávila Martínez — 28394

Luis Eliezer Rivera Gamez

Christian Joel de la fuente Marquez

ASESOR ACADÉMICO:

M.C.C. José Isidro Limones Martínez

Torreón, Coahuila.

Julio - Agosto 2026

INTRODUCCIÓN

Este reporte documenta Veta, un prototipo educativo de recomendación de video corto inspirado en problemas de personalización a gran escala. Su implementación local permite explorar recuperación de candidatos, filtros, puntuación multiobjetivo heurística y diversificación. La referencia a TikTok y Monolith ofrece contexto teórico; no implica acceso a los sistemas, datos ni infraestructura de ByteDance.

El estudio sigue las seis fases de CRISP-DM y usa un CSV exportado del laboratorio del prototipo. Orange Data Mining se empleó para construir y evaluar un clasificador exploratorio de abandono temprano. Se distinguen las mediciones reproducibles de los objetivos pendientes: el clasificador no está integrado en el feed, y el CSV sintético no demuestra cambios en retención real, equidad de exposición ni latencia de producción.

ÍNDICE

Capítulo I. Antecedentes

- A. Contexto de ByteDance / TikTok y Veta
 - i. Misión
 - ii. Visión
 - iii. Objetivos del proyecto
 - iv. Filosofía
- B. Planteamiento del problema

- C. Objetivo general del proyecto
- D. Objetivos específicos
- E. Propuesta de solución
- F. Justificación
- G. Alcances y limitaciones
- H. Metodología CRISP-DM
- I. Narrativa por capítulo

Capítulo II. Marco Teórico

- 2.1 Fundamentos de Minería de Datos y Procesamiento de Flujos Continuos
- 2.2 Representación Vectorial y Similitud Coseno
- 2.3 Puntuación Multiobjetivo y MMoE como Referente Teórico
- 2.4 Diversificación por Reglas y DPP como Referente Teórico

Capítulo III. Desarrollo

- 3.1 Arquitectura General del Pipeline de Recomendación
- 3.2 Comprensión y Preparación de Datos en Orange
- 3.3 Implementación del Prototipo y Modelado Exploratorio
 - 3.3.1 Etapa 1: Recuperación de Candidatos (Candidate Sourcing)
 - 3.3.2 Etapa 2: Filtrado de Seguridad e Integridad
 - 3.3.3 Etapa 3: Puntuación Multiobjetivo (Multi-Task Scoring)
 - 3.3.4 Etapa 4: Reordenamiento, Diversificación Semántica y Ensamblado

Capítulo IV. Resultados

- 4.1 Perfil y Calidad de los Datos de Laboratorio
- 4.2 Evaluación del Clasificador de Abandono Temprano

Capítulo V. Conclusiones y Recomendaciones

- a. Conclusiones
- b. Recomendaciones
- c. Trabajo futuro

Bibliografía

Apéndices

Anexos

CAPÍTULO I

ANTECEDENTES

A. Contexto de ByteDance / TikTok y Veta

ByteDance y TikTok se estudian como contexto de sistemas de recomendación de video corto. Veta es un desarrollo académico independiente; las pruebas de este informe corresponden exclusivamente al prototipo y a eventos sintéticos generados en su laboratorio.

i. Misión

Como contexto, TikTok declara la misión de inspirar creatividad y brindar alegría. La misión operativa de Veta es ofrecer un entorno reproducible para estudiar personalización, señales de consumo y evaluación de modelos.

ii. Visión

La visión del proyecto académico es disponer de un laboratorio local que permita medir el comportamiento del recomendador y contrastar hipótesis con datos trazables antes de proponer una aplicación real.

iii. Objetivos del proyecto

- Registrar interacciones con una definición clara de evento y unidad de análisis.
- Examinar abandono temprano, finalización, diversidad y exposición a contenido emergente en datos del laboratorio.
- Evaluar modelos con particiones independientes y documentar sus límites antes de

cualquier integración operativa.

iv. Filosofía

La filosofía de trabajo es separar hipótesis, implementación y evidencia. Las cifras del CSV sintético se interpretan como resultados del laboratorio, no como métricas de TikTok ni de usuarios reales.

B. Planteamiento del problema

En un feed de video corto, optimizar una sola señal puede favorecer recomendaciones repetitivas o con consumo superficial. Para estudiar este problema, Veta genera interacciones sintéticas y expone un recomendador modular. El problema de minería evaluado aquí es predecir el abandono temprano en eventos terminales, con especial cuidado de evitar variables que revelen la respuesta después de la reproducción.

C. Objetivo general del proyecto

Analizar el prototipo Veta mediante CRISP-DM y evaluar, con datos de laboratorio y Orange Data Mining, si las características disponibles antes de la reproducción permiten distinguir eventos de abandono temprano de eventos de finalización.

D. Objetivos específicos

- Describir el pipeline implementado de recuperación, filtrado, puntuación y diversificación, e identificar sus diferencias frente a arquitecturas teóricas como Monolith, MMoE, HNSW y DPP.
- Definir el objetivo `early_skip`, la unidad de análisis y las variables excluidas para prevenir fuga de información.
- Perfilar el CSV de laboratorio y preparar una muestra de eventos terminales con partición por sesión.
- Comparar modelos de clasificación mediante validación agrupada y prueba final en sesiones reservadas, informando AUC, precisión, sensibilidad, F1 y matriz de

confusión.

- Documentar limitaciones, riesgos de generalización e integración futura del modelo con el prototipo.

E. Propuesta de solución

Veta implementa un pipeline local configurable. Recupera candidatos por similitud coseno, afinidad temática/audio, exploración de publicaciones emergentes o popularidad para usuarios nuevos; aplica filtros; calcula cinco señales heurísticas ponderadas; y diversifica evitando repeticiones contiguas de autor, audio o categoría. Orange analiza el CSV exportado y produce un clasificador separado. HNSW, MMoE y DPP se mantienen como referentes para trabajo futuro, no como componentes ya ejecutados.

F. Justificación

El valor del proyecto consiste en disponer de un prototipo y una ruta de evaluación verificable. El análisis de datos permite detectar definiciones ambiguas, riesgos de fuga de información y diferencias entre un resultado de clasificación y una mejora del sistema de recomendación. Esta distinción es necesaria para tomar decisiones de ingeniería responsables.

G. Alcances y limitaciones

Alcances: el proyecto contempla lo siguiente:

- Implementación local de Veta con API FastAPI, PostgreSQL, MongoDB y cliente React para simulación, registro de eventos y consulta del feed.
- Pipeline heurístico configurable con recuperación, filtros, puntuación multiobjetivo y reglas de diversidad.
- Laboratorio de eventos sintéticos, exportación CSV y análisis reproducible del abandono temprano.
- Evaluación fuera de muestra del clasificador con sesiones reservadas; comparación con regresión logística como referencia.
- Identificación de riesgos de calidad, generalización, privacidad y monitoreo antes

de integrar el modelo.

Limitaciones: quedan fuera del alcance del proyecto los siguientes puntos:

- No se estudian datos ni sistemas internos de ByteDance. Los registros son sintéticos y los resultados no representan usuarios de TikTok.
- La partición por sesión reduce dependencia entre eventos, pero entrenamiento y prueba comparten el universo de usuarios y videos. No hay validación con usuarios, publicaciones o periodos nuevos.
- No se ha medido impacto causal del clasificador sobre retención, diversidad, equidad, ingresos, ROI ni latencia de producción; tampoco está desplegado en el ranking del feed.

H. Metodología CRISP-DM

Se aplicaron las seis fases iterativas de CRISP-DM con un entregable verificable en cada una:

- Comprensión del negocio: objetivo académico de estudiar abandono temprano y evaluar si existe señal predictiva útil; criterio de éxito: desempeño fuera de muestra y documentación de límites.
- Comprensión de datos: inspección de esquema, tipos de evento, usuarios, videos, sesiones, faltantes y filas idénticas del CSV exportado por el laboratorio.
- Preparación de datos: selección de eventos terminales complete y skip; etiqueta early_skip; exclusión de event_type, watch_ms y completion_ratio por fuga de información, y de identificadores directos.
- Modelado: Random Forest y regresión logística con variables previas a la reproducción. El modelo se entrenó como artefacto de Orange; el puntuador del feed permanece heurístico.
- Evaluación: validación agrupada por sesión en entrenamiento, selección de umbral y una prueba final en sesiones reservadas; análisis de AUC, precisión, sensibilidad, F1 y errores.
- Despliegue: se conserva el flujo .ows, las tablas y el modelo serializado para reproducir el experimento. Su incorporación al feed requiere pruebas de

integración, calibración y monitoreo.

I. Narrativa por capítulo

El Capítulo I presenta el problema, alcance y metodología CRISP-DM. El Capítulo II separa los conceptos de recomendación del comportamiento realmente implementado. El Capítulo III describe el software, los datos y el experimento de modelado con Orange.

El Capítulo IV comunica los datos observados y la evaluación fuera de muestra. El Capítulo V establece conclusiones limitadas a la evidencia, riesgos y pasos necesarios para futuras pruebas operativas.

CAPÍTULO II

MARCO TEÓRICO

2.1 Fundamentos de Minería de Datos y Procesamiento de Flujos Continuos

CRISP-DM organiza la minería de datos en comprensión del negocio, comprensión de datos, preparación, modelado, evaluación y despliegue. En este trabajo la fuente es una exportación de eventos sintéticos del laboratorio de Veta. Cada fila representa un evento, no necesariamente una reproducción independiente; por ello la unidad de modelado se restringe a eventos terminales.

Orange Data Mining permite explorar distribuciones, definir atributos y comparar clasificadores de forma visual. Aquí se usó para el flujo de clasificación de abandono temprano; no se atribuyen al experimento análisis PCA, K-Means o correlaciones que no quedaron documentados con datos verificables.

2.2 Representación Vectorial y Similitud Coseno

Veta representa afinidades del usuario y atributos del video con vectores y calcula

similitud coseno para ordenar candidatos. La implementación actual recorre y ordena el catálogo elegible en memoria; no utiliza un índice de búsqueda aproximada HNSW.

La afinidad existente entre el vector latente de intereses dinámicos del usuario y el vector representativo del video se determina mediante la similitud coseno. Esta relación matemática calcula el coseno del ángulo formado por ambos vectores en el espacio métrico:

$$\text{Similitud(Usuario, Video)} = (\text{Vector Usuario} \cdot \text{Vector Video}) / (\text{Magnitud del Usuario} \times \text{Magnitud del Video})$$

Monolith es una referencia de investigación sobre recomendación en tiempo real con tablas de embeddings dinámicos. Ese diseño no forma parte del código de Veta ni de las pruebas de este informe. En el prototipo, la similitud coseno es una señal de recuperación y puntuación.

2.3 Puntuación Multiobjetivo y MMoE como Referente Teórico

El consumo de videos cortos está guiado por comportamientos de distinta naturaleza. Por ejemplo, un usuario puede terminar de ver un video por simple inercia sin que realmente le agrade, o puede marcar un "me gusta" rápidamente sin ver el material completo. Por esta razón, basar el algoritmo en una sola métrica genera recomendaciones sesgadas.

MMoE es una arquitectura neuronal para aprendizaje multitarea. Veta no entrena ni ejecuta una red MMoE: calcula cinco salidas mediante fórmulas heurísticas basadas en afinidad, tema, audio y tasa previa de skip. Esta distinción impide interpretar sus salidas como probabilidades calibradas o como pérdidas optimizadas durante entrenamiento.

Tabla I. Cinco señales heurísticas del puntuador implementado en Veta

Identificador	Señal heurística	Cálculo implementado	Interpretación
Y1	Finalización	Sigmoide de afinidad, tema, audio y skip previo	Estimación no calibrada
Y2	Tiempo visto	Combinación acotada de afinidad, tema y skip	Razón estimada
Y3	Repetición	Sigmoide de afinidad y audio	Estimación no calibrada
Y4	Interacción social	Sigmoide de afinidad y tema	Estimación no calibrada
Y5	Abandono temprano	Sigmoide de afinidad, skip y tema	Penalización si supera 0.70

2.4 Diversificación por Reglas y DPP como Referente Teórico

Los DPP son un método de selección diversa estudiado en la literatura. Veta utiliza una regla codificada más simple: tras ordenar por puntuación, evita que videos contiguos repitan autor, audio o categoría cuando existen alternativas. No se calculó un DPP ni un índice cuantitativo de diversidad en este experimento.

CAPÍTULO III

DESARROLLO

3.1 Arquitectura General del Pipeline de Recomendación

El prototipo Veta filtra clips inactivos, bloqueados, vistos y duplicados antes de asignar los cupos de recuperación. Después reaplica filtros, puntúa y diversifica; el reciclaje omite hashes de contenido ya elegidos. Sus parámetros predeterminados son hasta 80 candidatos de origen, 40 tras la ordenación y 20 resultados finales: límites configurados, no mediciones de rendimiento.

Flujo Secuencial del Pipeline Algorítmico:




Fig. 1. Esquema del pipeline local. La elegibilidad se comprueba antes de recuperar y los filtros se reaplican sobre los candidatos.

3.2 Comprensión y Preparación de Datos en Orange

El archivo `veta_interactions.csv` contiene 12,271 filas de eventos sintéticos, 17 columnas, 80 usuarios, 210 videos y 524 sesiones. Los eventos `complete` (3,809) y `skip` (1,888) forman 5,697 registros terminales. En esta muestra todos los `skip` cumplen `early_skip=1`, definido en la exportación como `skip` con `watch_ms` menor de 2,000; esto no autoriza a redefinir la etiqueta como cualquier `skip` en otros conjuntos.

Flujo reproducible de datos y modelado en Orange Data Mining:



Fig. 2. Flujo de clasificación del abandono temprano; las tablas preparadas y el archivo .ows permiten repetirlo.

La tasa de early_skip entre eventos terminales es 33.14% (1,888/5,697). El CSV no contiene un identificador único de evento ni marca temporal: 5,040 filas son idénticas en sus 17 campos, pero no es posible decidir solo con este archivo si representan duplicados indebidos o interacciones coincidentes. campaign_id falta en 12,027 filas y pass_id en 6,271; se excluyeron del modelo. También se excluyeron watch_ms, completion_ratio y event_type porque revelan el desenlace.

3.3 Implementación del Prototipo y Modelado Exploratorio

3.3.1 Etapa 1: Recuperación de Candidatos (Candidate Sourcing)

La recuperación se realiza sobre el catálogo elegible en memoria. La configuración predeterminada reserva aproximadamente 60% de un máximo de 80 candidatos a similitud coseno, 30% a afinidad temática y 10% a exploración; los usuarios nuevos usan popularidad como alternativa. Los cupos reales dependen de disponibilidad y deduplicación.

- Canal vectorial: ordena por similitud coseno con el perfil del usuario; no se implementó HNSW ni un tiempo máximo de 8 ms.
- Canal temático: combina afinidad por categoría, audio y etiquetas existentes en el perfil.
- Canal exploratorio: prioriza publicaciones con menos de 100 reproducciones en el catálogo local. Esto crea una oportunidad de exposición, sin demostrar equidad de

distribución.

3.3.2 Etapa 2: Filtrado de Seguridad e Integridad

Los filtros comprueban que el video esté activo y sea elegible para el usuario; descartan contenido propio, visto, bloqueado, restringido por edad o duplicado según los campos disponibles. No hay modelos de análisis visual/textual ni detección perceptual de spam en esta implementación.

3.3.3 Etapa 3: Puntuación Multiobjetivo (Multi-Task Scoring)

El puntuador de Veta calcula cinco señales y_1 a y_5 mediante funciones deterministas; no existe una red MMoE entrenada en este módulo. Las señales representan finalización, tiempo visto, repetición, interacción social y riesgo de abandono como estimaciones heurísticas.

$$\text{Puntuación} = 0.35 \cdot y_1 + 0.30 \cdot y_2 + 0.15 \cdot y_3 + 0.12 \cdot y_4 - 0.08 \cdot y_5 + \text{ajustes de contexto}$$

La configuración aplica una penalización adicional de 0.45 cuando y_5 supera 0.70 y pequeños ajustes por coincidencia regional o seguimiento. Estos coeficientes son parámetros del prototipo, no pesos aprendidos ni evidencia de mayor retención.

3.3.4 Etapa 4: Reordenamiento, Diversificación Semántica y Ensamblado

Tras puntuar, Veta conserva hasta 40 candidatos y diversifica hasta 20 resultados. La regla voraz evita repeticiones contiguas de autor, audio o categoría y procura incluir un clip elegible de la región del usuario. No implementa DPP.

CAPÍTULO IV

RESULTADOS

4.1 Perfil y Calidad de los Datos de Laboratorio

La evidencia procede de una exportación puntual del generador de eventos

sintéticos del laboratorio, no de una simulación verificada de 30 días con 10,000 usuarios. Ese generador no llama a rank_organic_feed: los cambios recientes de filtrado previo y reciclaje del feed no recalculan este CSV ni las métricas de Orange. La tabla resume conteos observados. No existe un experimento A/B ni medición comparable de retención, ROI o latencia P99.

Tabla II. Perfil verificable de la exportación y alcance de las métricas

Métrica evaluada	Valor observado	Unidad / base	Procedencia	Alcance
Eventos exportados	12,271	Filas / 17 columnas	CSV de laboratorio	Eventos sintéticos
Usuarios y videos	80 / 210	IDs distintos	CSV de laboratorio	Sin muestra externa
Sesiones	524	IDs distintos	CSV de laboratorio	Sin tiempo en CSV
Eventos terminales	5,697	3,809 complete + 1,888 skip	CSV de laboratorio	Base del modelo
Abandono temprano	33.14%	1,888 / 5,697 terminales	CSV de laboratorio	Solo esta muestra
Filas idénticas	5,040	17 campos iguales	CSV de laboratorio	Sin event_id para resolver

Las categorías de evento son heterogéneas: una reproducción puede generar varias filas (impresión, play, heartbeat, interacción y término). Por ello, 3,809 complete y 1,888 skip se interpretan como eventos terminales; el porcentaje de finalización dentro de ese subconjunto es 66.86%. No debe extrapolarse a una tasa de éxito de usuarios

reales ni a una mejora del ranking.

4.2 Evaluación del Clasificador de Abandono Temprano

Se reservaron 94 sesiones (1,171 eventos terminales) para prueba final y se entrenó con 373 sesiones (4,526 eventos). La selección de umbral 0.24 se hizo con validación agrupada por sesión dentro del entrenamiento. Random Forest obtuvo AUC-ROC 0.850, precisión 0.700, sensibilidad 0.731 y F1 0.715 para early_skip=1 en la prueba reservada. La regresión logística de referencia obtuvo AUC-ROC 0.702 en esa misma prueba.

Tabla III. Matriz de confusión de Random Forest en sesiones reservadas (umbral 0.24)

Clase real	Predicción: finalización (0)	Predicción: abandono (1)	Total real
Finalización (0)	605 correctas	135 falsas alarmas	740
Abandono temprano (1)	116 no detectados	315 correctos	431

La exactitud global fue 78.57% (920/1,171). De los 431 abandonos tempranos reales, 315 se detectaron y 116 no; de las 740 finalizaciones, 605 se clasificaron correctamente y 135 se marcaron como abandono. El AUC mide discriminación en esta muestra; no demuestra calibración ni desempeño en producción.

Límites de generalización y decisión de integración:

La partición por sesión evita mezclar una misma sesión entre entrenamiento y prueba, pero usuarios, videos, temas y audios pueden reaparecer en ambos grupos.

Antes de integrar el modelo: validar con usuarios y videos nuevos, periodo posterior, calibración por región y categoría, deriva de datos, latencia y efectos del feed en una prueba controlada.

El archivo CSV no contiene una asignación experimental de usuarios a versiones del recomendador. Por tanto, no se calculan mejoras causales de diversidad, equidad, permanencia o satisfacción. El clasificador aporta una línea de base para investigación, no una validación del sistema de recomendación completo.

CAPÍTULO V

CONCLUSIONES Y RECOMENDACIONES

a. Conclusiones

El proyecto dispone de un prototipo funcional de recomendación heurística y de un flujo reproducible de minería de datos alineado con CRISP-DM. El laboratorio produjo 12,271 eventos sintéticos; 5,697 eventos terminales permitieron evaluar un clasificador de abandono temprano con AUC-ROC 0.850 en sesiones reservadas.

El resultado solo respalda la discriminación en esta muestra. No se entrenó MME ni se implementaron HNSW o DPP; tampoco se demostró una mejora del feed. El filtrado previo evita gastar cupos en clips ilegibles y el reciclaje impide hashes repetidos, pero su efecto cuantitativo sobre el feed requiere una prueba separada. La ausencia de fecha/ID de evento y el solapamiento de usuarios y videos entre particiones limitan la generalización.

b. Recomendaciones

Para continuar el trabajo se recomiendan acciones verificables:

- Añadir `event_id`, fecha/hora, versión de política de recomendación y `run_id` a la exportación; validar la semántica de cada evento y conservar un diccionario de datos.
- Repetir la evaluación con usuarios, videos y periodos realmente nuevos; informar

precisión, sensibilidad, F1, AUC y calibración por segmentos, junto con intervalos de incertidumbre.

- Medir latencia, diversidad, exposición y retención en un experimento controlado antes de afirmar impacto o calcular retorno económico; definir monitoreo de deriva, privacidad y criterios de reversión.

c. Trabajo futuro

El trabajo futuro prioriza la conexión cuidadosa entre análisis y producto:

- Integrar opcionalmente el clasificador como una señal del puntuador y verificar que no introduzca sesgos por región, categoría, usuario nuevo o creador emergente.
- Comparar el pipeline heurístico con líneas de base de recomendación bajo el mismo catálogo y la misma asignación experimental; estudiar por separado el módulo publicitario ya presente en Veta.
- Evaluar métodos más complejos como MMoE, índices aproximados y DPP solo si los datos, las pruebas y el costo operativo justifican su implementación.

BIBLIOGRAFÍA

a. LIBROS:

Deitel, P. J., y Deitel, H. M. (2020). *Java How to Program: Early Objects* (11a ed.). Nueva York: Pearson Educación.

Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep Learning* (1a ed.). Cambridge, Massachusetts: MIT Press.

Han, J., Kamber, M., y Pei, J. (2012). *Data Mining: Concepts and Techniques* (3a ed.). Waltham, Massachusetts: Morgan Kaufmann Publishers.

Leskovec, J., Rajaraman, A., y Ullman, J. D. (2020). *Mining of Massive Datasets* (3a ed.). Cambridge: Cambridge University Press.

b. REVISTAS Y ARTÍCULOS DE CONFERENCIA:

Chen, L., Zhang, G., y Zhou, E. (2018). Fast Greedy MAP Inference for Determinantal Point Processes to Improve Recommendation Diversity. *Proceedings of the 32nd Conference on Neural Information Processing Systems (NeurIPS)*, 31(1), 5622-5633.

Covington, P., Adams, J., y Sargin, E. (2016). Deep Neural Networks for YouTube Recommendations. *Proceedings of the 10th ACM Conference on Recommender Systems (RecSys)*, 10(1), 191-198.

Demsar, J., Curk, T., Erjavec, A., Gorup, C., Hocevar, T., Milutinovic, M., y Zupan, B. (2013). Orange: Data Mining Toolbox in Python. *Journal of Machine Learning Research (JMLR)*, 14(1), 2349-2353.

Liu, X., Zhao, P., Zhou, B., Wang, K., y Zhang, Y. (2022). Monolith: Real Time Recommendation System with Collisionless Embedding Table. *arXiv preprint arXiv:2209.07602*, 1-12.

Ma, J., Zhao, Z., Yi, X., Chen, J., Hong, L., y Chi, E. H. (2018). Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts. *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 24(1), 1930-1939.

c. PÁGINAS WEB Y REPOSITORIOS ESPECIALIZADOS:

Repositorio local del proyecto Veta. (2026). Código de API, recomendador, simulador, exportación CSV y documentación técnica. Evidencia inspeccionada en E:\Tiktok.

Orange Data Mining. (2026). Documentación y aplicación de análisis visual. Disponible en: <https://orangedatamining.com/> [consulta: septiembre de 2026].

CRISP-DM Consortium. (2000). CRISP-DM 1.0: Step-by-step data mining guide. Marco metodológico de seis fases.

APÉNDICES

Apéndice A. Lógica del Puntuador Heurístico Implementado

El siguiente resumen corresponde al código local del prototipo y no a una inferencia neuronal de ByteDance:

- Paso 1: Obtener atributos de usuario, video y contexto; determinar elegibilidad y fuentes de candidatos.
- Paso 2: Calcular y_1 a y_5 con funciones heurísticas de afinidad vectorial, tema, audio y tasa previa de skip.
- Paso 3: Aplicar una penalización de 0.45 si y_5 supera el umbral configurado de 0.70.
- Paso 4: Sumar las señales con pesos 0.35, 0.30, 0.15, 0.12 y -0.08 , más ajustes de contexto.
- Paso 5: Ordenar, seleccionar hasta 40 candidatos y diversificar hasta 20 resultados.

ANEXOS

Anexo 1. Especificaciones Técnicas del Entorno de Simulación Experimental

- Entorno: prototipo local con API FastAPI, PostgreSQL, MongoDB y cliente React. No se verificó un clúster AMD EPYC ni un despliegue distribuido de producción.
- Datos de esta evaluación: CSV de 12,271 filas y 17 columnas; 80 usuarios, 210 videos, 524 sesiones y 5,697 eventos terminales. No se documentan 10,000 perfiles, 50,000 videos ni 500,000 eventos.
- Artefactos reproducibles: `veta_modelado.ows`, `veta_terminal_train.tab`, `veta_terminal_test.tab`, `veta_early_skip_model.pkcls` y `veta_early_skip_report.json`. La partición final se hizo por sesión; no equivale a una validación en usuarios o videos nuevos.